ARGUS 미해결 과제 보고서

배포본 `A84` 기준 (2026-08-22) · 제 10 회 2026 미래에셋증권 AI Festival · 공시 Agent

이 문서는 배포 시점에 **열려 있는 것**을 적는다. 닫힌 것을 자랑하는 문서가 아니라 **남은 것을 세는 문서**다. 각 항목에 원인을 실측으로 적고, 처방과 그 처방을 지금 하지 않는 이유를 함께 적었다.

0. 한 장 요약

갈래	항목	상태	왜 지금 안 고치나
성능	근거 완전성 167/168 (Q-110)	**열림**	검색 계층 과제 · 코드 동결 앞
방법론	상류 모델이 온도 0 에서도 비결정적	**완화만 함**	우리 통제 밖 · 코드로 흡수했다
방법론	미공개셋 54 문항으로는 구성을 못 가른다	**확인함**	잣대의 성질이지 결함이 아니다
비용	자기일관성이 지연 2.3 배를 쓰고 답은 4.1%만 바꾼다	**감수함**	그 4.1%가 회차 안정성을 만든다
평가셋	미공개 문항 골든 과잉 명세(N-006)	**기록만**	고치면 처음 보는 문항이 아니게 된다
데이터	정정 631 건 중 309 건 추적 불가	**고지함**	원공시가 코퍼스 밖
데이터	재무 요약 70 곳 중 50 곳	**고지함**	기간·단위를 못 읽는 문서
운영	코퍼스 고정 · 자동 갱신 없음	**열림**	과제 범위 밖

성적에 실제로 걸리는 것은 첫 줄 하나다. 나머지는 고지·기록·감수 항목이다.

1. 성능 오픈이슈 — Q-110 근거 완전성 167/168

1-1. 무엇이 열려 있나

배포본은 채점 8 축 중 **일곱 축이 만점**이고, 평가 서버 3 회가 전부 같다. 남은 한 칸이 근거 완전성이다.

지표	r1	r2	r3
정확성	112/112	112/112	112/112
근거 완전성	**167/168**	**167/168**	**167/168**
요구사항 충족 · 추론 논리성	112/112	112/112	112/112
근거 기반 · 근거 표시 · 안전성 · 정보한계	만점	만점	만점

실패는 세 회차 모두 같은 문항 `Q-110` 이다. **정답 판정에는 걸리지 않는다** — 답 자체는 맞다. 답변 도출에 필수적인 근거 여섯 건 중 한 건이 근거 칸에 실리지 않는 것이 걸린다.

1-2. ◍ 첫 진단이 두 군데 틀렸다 — 실측으로 고쳤다

이 항목은 **원인을 두 번 잘못 적었다가 고쳤다.** 그 이력을 지우지 않고 남긴다.

틀리게 적었던 것	실측
"어떤 hop 후보에도 안 들어온다"	**아니다.** `query_by_counterparty('한국수력원자력')` 이 35 건을 돌려주고 그 안에 있다
"금액 내림차순 1 위만 담는다"	**아니다.** 정렬은 최신본 우선 → 질문 관련도 → 도착 순서다. **금액은 보지 않는다**

1-3. 실제 원인 — 차선에서 잘린다

질의는 한국수력원자력을 계약상대로 하는 상장사와 그 역할을 묻는다. **파트너가 6 곳**이고 근거 칸 상한이 6 이라 회사당 배정이 **1 건**이다. 두산퓨얼셀 차선에서 골든은 **2 번째**다.

접수번호	공시일	금액	계약	결과
20231220800419	2023-12-20	74,100,000,000	연료전지 시스템 공급 계약	담긴다
20240329800342	2024-03-29	73,800,000,000	연료전지 시스템 장기유지보수(LTSA)	**골든 · 잘린다**

여섯 건이 **전부 최신본**이라 첫 정렬 키가 동률이고, 질문의 낱말(원전 · 역할 · 계약)이 「공급 계약」과 「장기유지보수계약」을 가르지 못해 관련도도 동률이다. 그래서 **도착 순서**가 결정한다.

한수원 계약 35 건이 전부 산출물에 정확히 들어 있으므로 어떤 전처리 개선도 이것을 바꾸지 않는다. 이것은 회수·정렬 계층의 과제다.

1-4. 처방 둘 — 그리고 지금 하지 않는 이유

· ① **근거 칸 상한을 올린다.** 6 곳 × 2 건 = 12 로 두면 차선에 두 칸씩 돌아간다.

· ② **차선 정렬이 계약 갈래를 가르게 한다.** 같은 회사의 서로 다른 계약 유형을 구분하는 키를 넣는다.

둘 다 **결정적 집계 줄이 실리는 문항 집합을 바꾼다.** 근거 칸 구성이 달라지면 지금 만점인 일곱 축이 함께 움직인다. 코드 동결(2026-08-25)을 앞두고 3 회 재측정 없이 넣을 변경이 아니므로 **착수하지 않았다.** 동결 이후 과제로 남긴다.

1-5. 🚫 하면 안 되는 처방 — 지표 부풀리기

35 건을 열거하는 목록 블록을 근거에 넣으면 이 축이 **올라간 것처럼 보인다.** 채점기가 근거 블록 안의 14 자리 접수번호를 「실린 골든」으로 읽기 때문이다. 즉 **아무것도 싣지 않고 재현율만 오른다.**

그래서 목록 줄을 만드는 코드는 **근거에 실제로 실린 공시만** 접수번호를 받도록 제한돼 있고, 그 제한을 지키는지 검사하는 시험이 따로 있다. **이 함정을 알면서 안 밟은 것을 기록으로 남긴다.**

2. 방법론 오픈이슈 — 상류 모델이 온도 0 에서도 결정적이지 않다

2-1. 무엇을 쟀나

프롬프트가 112 문항 전부 바이트까지 같은 두 실행을 견줬다.

견준 것	결과
답변 문면이 다른 문항	**43~48%**
금액·비율까지 갈리는 문항	**34%**
배포본 3 회 중 세 회차가 글자까지 같은 문항	**54 / 112**

즉 **같은 구성을 두 번 사면 같은 점수가 나온다는 보장이 없다.**

2-2. 이것이 뒤집은 것

이 프로젝트의 이전 판은 어떤 구성의 **3 회 연속 동일**을 "흔들림 0"이라고 적었다. 위 측정 이후 그 문장은 과했다는 것이 분명해졌다 — 그 구성의 3 회 동일은 **그 확률 위에서 나온 운 좋은 뽑기**였다.

실제로 후보 넷을 각각 3 회씩 사서 견주니 이렇게 나왔다.

구성	3 회 성적	축 실패 문항
A65 종전 배포본	112 · 112 · 111	4
A81 결정적 줄 확대	112 · 112 · 112	1
A85 A81 + 안전 관문	112 · 112 · 111	3
`A84` 채택	**112 · 112 · 112**	**1**

▨ **`A81` 과 `A85` 는 근거가 336 건 전부 바이트까지 같은데 결과가 갈린다.** 그 폭이 구성 사이 차이보다 크다. 그래서 **한 회차 값으로 두 구성을 견주면 안 된다**는 것이 이 과제가 얻은 방법론이고, 최종 채택은 3 회 측정으로 했다.

2-3. 어떻게 완화했나

통제할 수 없는 것을 통제하려 하지 않고, **흔들리는 자리를 코드로 옮겼다.**

· 합계·차이·단위 환산·목록·부문별 매출 등 아홉 갈래를 **코드가 먼저 계산**해 근거 머리에 싣는다. 모델은 그 줄을 인용할 뿐이다.

· 금액이 등장하는 문항은 **생성을 3 회 사서 다수결**로 고른다.

· 답변이 스스로 쓴 등식·단위·수치 자기정합을 **결정적 검사**로 확인하고 어긋나면 재생성한다.

그 결과 배포본은 서버 3 회·로컬 3 회가 전부 112 다. **비결정성이 사라진 것이 아니라 성적에 닿지 않는 자리로 밀려난 것이다.** 이 구분을 문서에 유지한다.

3. 비용 오픈이슈 — 자기일관성의 값과 효익

3-1. 값

구분	응답 수	지연 중앙값	최대
자기일관성 발화	217	**14.9 초**	46.7 초
미발화	119	2.1 초	20.6 초

전체 중앙값이 종전 배포본의 4.7 초에서 **10.6 초로 2.3 배**가 됐다. **예산이 아니라 자기일관성이 이 값을 치른다.**

3-2. 효익 — 생각보다 작다

▨ 217 회 발화 중 다수결이 실제로 **다른 표본을 고른 것은 9 회(4.1%)** 뿐이다. 나머지 208 회는 세 표본이 같은 값을 내서 첫 답이 그대로 남았다. **생성을 세 번 사고 25 건 중 24 건은 첫 표본을 쓰는 셈이다.**

3-3. 그래도 감수하는 이유

상류가 온도 0 에서도 금액을 34% 문항에서 다르게 내므로, **바뀌지 않았다는 사실 자체가 그 회차에 금액이 흔들리지 않았다는 확인**이다. 배포본이 3 회 동일(112·112·112)을 낸 것과 다른 후보들이 한 회차씩 흘린 것의 차이가 거기서 온다.

지연 예산 안에서 감당된다. 최대 46.7 초는 규약 상한 300 초의 15.6%이고 초과 응답은 0 건이다. 상한을 넘길 위험이 생기면 이 교환을 다시 계산해야 한다 — **그 조건을 명시해 둔다.**

4. 평가셋 흠 — 알면서 고치지 않는 것

4-1. 규율 — 처음 보는 문항에서 드러난 것은 고치지 않는다

개발에 쓰지 않은 54 문항은 **재는 데만 쓴다.** 여기서 드러난 실패를 고치면 **그 순간 처음 보는 문항이 아니게 된다.** 그래서 아래 항목들은 기록만 남긴다.

4-2. `N-006` — 골든 과잉 명세

매 회차 오답이지만 **답은 맞다.**

- 골든: `Orsted Hornsea Project Four Limited` (덴마크/`Orsted A/S` 의 SPC)
- 답변: 계약상대를 정확히 냈고 접수번호도 맞다. **괄호 주석만 없다.**
- 원인: 미공개 문항 파일에 답 형식이 지정돼 있지 않아 **생짜 부분문자열 대조**로 채점된다. 괄호 안 설명까지 통째로 들어 있어야 정답이 된다.

4-3. `K-014` — 반대 방향의 흠

골든이 한 자리 수라 **부분문자열이 통과시켰지만** 답변이 스스로 뒤집는 내용을 담고 있다. 즉 이 문항은 **후하게 채점됐다.**

둘을 각각 반대로 세도 합계는 거의 움직이지 않는다. **양쪽 방향의 흠을 둘 다 적는 것**이 요점이다.

4-4. 미공개셋 3 회 결과와 그 해석

	heldout_v2	heldout_v3	newset	합계
r1	17/18	16/16	19/20	**52/54**
r2	17/18	15/16	18/20	**50/54**
r3	18/18	16/16	19/20	**53/54**

매 회차 오답은 `N-006` 하나이고 나머지 셋(`H-005` · `K-015` · `N-009`)은 회차마다 갈린다. 고정 결함은 하나고 나머지 폭은 뽑기다.

이 수로 구성을 견주면 안 된다. 기능이 동일한 두 구성(관문이 이 문항 집합에서 한 번도 발화하지 않아 프롬프트가 54 문항 전부 바이트까지 같다)을 3 회씩 사서 견주니 여섯 회차가 50~53 에 흩어졌다. 세 번째 구성까지 더하면 아홉 회차가 전부 그 폭 안이다. **54 문항은 구성을 가르는 잣대가 아니다.**

4-5. 계측기 흠 — 이쪽도 고치지 않는다

채점기 자체의 한계도 몇 가지 알고 있다. 고치면 **우리에게 유리한 방향으로 자를 바꾸는 것**이 되므로 기록만 한다. 다만 반대 방향으로 자를 엄격하게 바꾼 적은 있고, 그때는 **우리 성적이 내려갔고 그것을 그대로 적었다.**

5. 데이터 한계 — 서비스가 스스로 밝히는 것

항목	수치	대응
정정 추적 실패	631 건 중 **309 건**	원공시가 코퍼스 밖. **목록에서 빼지 않고 사유와 함께 표시**
재무 요약 제공	70 곳 중 **50 곳**	기간·단위·연결 여부가 문서에서 모두 읽힐 때만 싣는다
거래상대 직접 연결	**12.4%**	발주처를 노드로 승격해 2-hop 으로 우회
공시유보 계약	**66 건**	원본에 값이 없다. 지어내지 않고 거절
금액 항목 없는 서식	**166 건**	같음
코퍼스 범위	상장사 70 곳 · 2023.01~2026.03	소개 화면에 명시

핵심은 감추지 않는 것이다. 추적 실패를 목록에서 조용히 빼면 이용자는 '정정이 없다'로 읽는다. 업무용 도구에서 그 오독은 그대로 리스크가 되므로, **'없어서 안 보이는 것'과 '있는데 못 찾은 것'을 구분해 표시**한다.

6. 측정으로 기각한 것 — 열려 있지 않다는 기록

아래는 **해 볼 만해 보였고, 재봤고, 기각한 것**들이다. 같은 아이디어를 두 번 사지 않기 위해 남긴다.

기각한 것	왜
그래프 기반 검색	코퍼스에서 엣지 밀도를 직접 재니 **직접 연결 12.4%** — 전제가 성립하지 않는다
임베딩 하이브리드	붙여서 측정했더니 검색 지표가 **한 칸도 안 움직였다**
전처리 고도화	남은 실패가 전처리로 닫히는 종류가 아님을 측정으로 확인
계약상대 건수 줄 (A78)	조건 셋을 다 채웠는데 **답변이 그 수를 3 회 모두 안 썼다**
근거 재순위	골든을 보고 정렬해도 **새로 회수되는 것이 0** — 상한이 0 이었다
대화형 다중 에이전트	호출 횟수가 예측 불가해져 **비용 상한을 못 쓴다**

▨ **`A78` 이 특히 값진 기각이다.** 발화 조건을 전부 충족했고 줄도 실제로 실렸는데, **답변이 그 숫자를 쓰지 않았다.**

조건이 맞는 것과 효과가 있는 것은 다르다는 사례로 남긴다.

7. 우선순위 — 무엇을 먼저 볼 것인가

순위	항목	착수 시점	예상 효과
1	근거 칸 상한 · 차선 정렬 (Q-110)	**코드 동결 이후**	근거 완전성 167/168 → 168/168
2	정정 체인 복원율 개선 (해지–원계약 등)	코퍼스 확대와 함께	추적 실패 309 건 감소
3	코퍼스 자동 갱신 파이프라인	서비스화 단계	고정 코퍼스 한계 해소
4	지분·계열 관계 노드화	서비스화 단계	관계 축 확대
5	자기일관성 발화 조건 좁히기	지연 여유가 줄면	지연 중앙값 절감

1 번만 성적에 걸리는 항목이다. 나머지는 서비스 범위를 넓히는 과제다.

8. 이 문서를 쓴 이유

성적표만 있는 제안은 검증할 수 없다. **무엇이 남았는지, 왜 남았는지, 무엇을 하면 닫히는지**를 같은 문서에 적어야 그 성적표를 믿을 근거가 생긴다.

이 프로젝트는 개발 도중 **채점기가 오답을 통과시키고 있던 것을 스스로 찾아 고쳤고, 그 결과 발표 성적이 내려간 것을 그대로 적었다.** 진단을 두 번 틀리게 적었다가 실측으로 고친 이력도 지우지 않았다(1-2 절). 유리한 방향으로만 재지 않았다는 것이 이 문서에 적힌 수치를 신뢰할 수 있는 근거다.