ARGUS 미해결 과제 보고서

배포본 `A92` 기준 (2026-08-28) · 제 10 회 2026 미래에셋증권 AI Festival · 공시 Agent

이 문서는 배포 시점에 **열려 있는 것**을 적는다. 닫힌 것을 자랑하는 문서가 아니라 **남은 것을 세는 문서**다. 각 항목에 원인을 실측으로 적고, 처방과 그 처방을 지금 하지 않는 이유를 함께 적었다.

0. 한 장 요약

채점 여덟 축이 평가 서버 3 회 내내 만점이다. 그래서 이 문서가 세는 것은 성적이 아니라 **성적에 안 잡히는 것**들이다.

갈래	항목	상태	왜 지금 안 고치나
문면	`Q-012` 가 「동일」과 「증가」를 한 답변에 함께 쓴다	**열림 (2/3 회차)**	근본 처방이 **색인 재빌드**다
기전	재생성이 검증 사유의 숫자를 베낀다	**열림 (드묾)**	재생성 프롬프트를 건드려야 한다
기전	재생성 과정이 배달 문면에 드러난다	**열림**	골든셋 0 건 · 미공개셋 2 건
기전	🟫 총액 가드가 한 번도 발화하지 않았다	**미검증**	넣었으나 498 응답에서 발화 0
방법론	상류가 온도 0 에서도 비결정적	**완화만 함**	우리 통제 밖 · 코드로 흡수했다
방법론	🟫 미공개셋의 독립성을 **두 번** 썼다	**되돌릴 수 없음**	08-26 설계 판단 · 08-28 결함 진단
평가셋	미공개 문항 골든 과잉 명세(`N-006`)	**기록만**	고치면 처음 보는 문항이 아니게 된다
데이터	정정 631 건 중 309 건 추적 불가	**고지함**	원공시가 코퍼스 밖
데이터	재무 요약 70 곳 중 50 곳	**고지함**	기간·단위를 못 읽는 문서
운영	코퍼스 고정 · 자동 갱신 없음	**열림**	과제 범위 밖

1. 마지막까지 열려 있던 축 — 그리고 어떻게 닫았나

여덟 축 중 **근거 완전성**만 여섯 회차 내내 167/168 이었다. 그 한 칸의 이력을 적는다. 지금은 닫혔지만, **어떻게 닫았는지가 남은 과제의 성격을 설명한다.**

1-1. 원인 — 회수가 아니라 배분이었다

`Q-110` 은 한국수력원자력을 계약상대로 하는 상장사와 그 역할을 묻는다. 필수 근거 여섯 중 `20240329800342`(두산퓨얼셀 장기유지보수계약)가 답변 근거에 안 실렸다.

🟢 **이 항목은 원인을 두 번 잘못 적었다가 고쳤다.** 그 이력을 지우지 않는다.

틀리게 적었던 것	실측
"어떤 hop 후보에도 안 들어온다"	**아니다.** `query_by_counterparty` 가 35 건을 돌려주고 그 안에 있다
"금액 내림차순 1 위만 담는다"	**아니다.** 정렬은 최신본 → 질문 관련도 → 도착 순서다. **금액은 안 본다**

진짜 원인은 칸 수였다. 파트너가 6 곳인데 근거 칸 상한이 6 이라 **회사당 1 건**이다. 그런데 두산퓨얼셀은 같은 발주처에 **두 갈래**를 맡는다.

접수번호	금액	계약
20231220800419	74,100,000,000	연료전지 시스템 **공급**
20240329800342	73,800,000,000	연료전지 시스템 **장기유지보수(LTSA)**

설비를 741 억에 팔고 그 설비를 738 억에 관리하는 구조다. 골든도 *"공급·장기유지보수(LTSA)를 맡는다"* 로 둘을 함께 적는다. **한 칸으로는 반쪽만 들어간다.**

1-2. 🟢 LLM 으로 고르는 길을 먼저 재고 기각했다

배분을 모델에게 맡기면 나아질지부터 쟀다. 파트너마다 후보 목록을 주고 *"이 회사의 역할을 가장 잘 보여 주는 것 하나"* 를 고르게 했다.

골든 적중 지금 규칙 5/6 · LLM 5/6 한 칸도 안 움직였다

모델도 우리 규칙과 똑같이 「공급 계약」을 집었다. 더 크고 더 기본적인 계약이니 자연스러운 선택이다. 즉 **「어느 것」이 아니라 「몇 개」 문제**였고, 하나만 고르는 한 누가 고르든 반쪽이다.

이로써 검색·집계 구간에 LLM 을 넣는 실측이 셋이 됐다.

실험	결과
`function_calling` — 모델이 도구를 고른다	전체 **74/88 대 81/88** (−7 문항)
`ORACLE` — 검색을 골든으로 완전히 고정	정답률 **+0.0%p**

이번 — LLM 이 근거 칸을 배분	**변화 0**

셋 다 같은 방향을 가리킨다. **이 구간의 상한은 이미 닿아 있다.**

1-3. 상한을 8 로 정한 것도 측정이다

칸을 몇으로 올릴지는 오프라인 산술로 정했다(LLM 0 회).

문항	6 칸	8 칸	9 칸	10 칸	12 칸
Q-110	4/6	**5/8**	5/9	5/10	5/10
Q-116	2/3	**3/5**	3/5	3/5	3/5
Q-109	2/6	2/8	2/9	2/10	2/10

8 에서 이미 최대치에 닿고 그 위로는 근거만 길어진다. 근거는 길수록 위험하다 — ORACLE 실험에서 옆 블록을 **치웠더니** 세 문항이 오답 → 정답이 됐다(희석). 그래서 얻는 것이 같은 최소값을 골랐다.

1-4. 부작용과 그 처방

칸을 넓히자 한 회사에 근거가 여러 건 실렸고, 모델이 **그것을 스스로 더했다.** Q-110 이 한전기술 3 건을 합해 1,080,964,550,138 원 을 냈는데 **진짜 합(1,081,829,074,942)과도 다른 수**였다.

verify_number_provenance 가 잡았다 — 1,680 응답에서 이 갈래는 **2 회뿐이고 오탐 0** 이다. **탐지는 완벽한데 갈아끼울 값을 모른다.**

「합계가 보이면 무조건 재계산」도 재보고 기각했다. 답변이 합계를 말하는 자리가 1,680 응답 중 **138 회 · 11 문항**인데 그중 **136 회는 이미 맞다.** 대부분은 계산이 아니라 공시에 적힌 총액의 인용이라 재계산 대상이 아니다.

대신 **합계를 아예 안 만들게** 했다 — 로스터 줄이 이미 회사마다 대표 계약과 금액을 주므로 더할 이유가 없고, 그 사실을 문면으로 말한다.

2. 열려 있는 것 ① — Q-012 가 「동일」과 「증가」를 함께 쓴다

2-1. 무엇이 남았나

Q-012 는 두 대량보유보고서를 견주라는 문항이다. 수치는 전부 맞다.

보유주식등 196,488,145 → 196,506,795 18,650 주 증가 ☑ 3 회 전부 기간 12 개월 ☑ 3 회 전부

그런데 서술 한 절이 이렇게 남는다(3 회 중 2 회).

> 주요 계약 체결 주식 등이 **동일하게** 92,270,920 주로 유지되었고 …

골든 요점 3 은 **"84,282,066 주에서 92,270,920 주로 증가"** 다. 같은 답변 안에 「증가량 7,988,854 주」도 함께 적혀 있어 **자기모순**이다.

2-2. 원인 — 근거에 범위가 다른 두 참말이 있다

결정적 줄(보고서 **사이**) 2025-03-10 84,282,066 → 2026-03-05 92,270,920 증가 원시 블록(2026 보고 **안**) 직전 92,270,920 → 이번 92,270,920 변동 없음

둘 다 참인데 재는 구간이 다르다. 모델이 **수는 앞에서, 서술은 뒤에서** 가져온다.

2-3. 세 처방을 다 재봤고 셋 다 막혔다

처방	결과
결정적 줄이 방향을 못 박는다	**부분 성공** — A84 6/6 회차 → A91 2/3 로 줄었지만 안 죽는다
산문을 정규식으로 고쳐 쓴다	**기각** — 관측된 일곱 문장에 대고 재니 셋은 고쳐지고 **넷이 망가졌다**(뜻이 사라지거나 어색해짐)
문장을 통째로 지운다	**불가** — 그 문장에 골든 요점 3 이 요구하는 92,270,920·14.40% 가 있어 지우면 채점이 깨진다
근거의 원시 줄에 범위를 라벨로 박는다	**근본 처방이나 지금 못 한다** — 아래

2-4. 근본 처방과 그 비용

원시 줄에 *"(이 보고서 한 건 안의 변동)"* 을 붙이면 두 참말의 공존이 사라진다. 그런데 그 줄은 **런타임이 아니라 색인 빌드 타임에 굳는다**(build_index.py 가 to_markdown 결과를 저장한다).

- 색인을 안 다시 지으면 **아무 효과가 없다**
- 다시 지으면 문서 텍스트가 바뀌어 **BM25 항 통계가 움직이고 112 문항 전부의 검색 순위가 흔들릴 수 있다**
- 게다가 _record_fields 가 그 줄을 **글자 그대로 재구성해** 찾으므로 그쪽도 함께 고쳐야 한다

즉 「근거 한 줄에 라벨 붙이기」가 아니라 **색인 재빌드 + 전 문항 재측정**이다. 제출을 앞두고 댈 규모가 아니다.

3. 열려 있는 것 ② — 재생성이 검증 사유의 숫자를 베낀다

3-1. 기전

① 어느 근거 레코드도 답변의 수를 설명하지 못한다 → 검증 실패 ② 실패 사유 하나가 뽑혀 재생성 프롬프트에 실린다 ③ 모델이 그 사유에 적힌 숫자를 그대로 베껴 쓴다

실제로 이렇게 나왔다(A86 Q-112).

> 대우건설의 해지 금액은 **350,500,000,000 원**입니다. 이는 **'[투자판단 관련 주요경영사항]' 공시에서 확인됩니다.**

골든은 1,147,665,603,998 원이다. 모델이 **사유 문자열의 숫자와 그 출처를 함께 옮겨 적었다.**

3-2. 이 갈래를 가르는 값싼 표지가 없다

후보 일곱을 59 건 전부에 대고 쟀다.

후보	결과
① 자기일관성이 만장일치면 못 뒤집는다	Q-061·Q-113 **24 회** 깨짐
② 답변값이 결정적 줄에 있으면	같은 24 회 깨짐
③ 재계산값이 결정적 줄에 있어야	Q-061 12 회 깨짐
④ 배율 임계	Q-065 3.29 · Q-109 3.25 대 Q-112 3.27 — **구분 불가**
⑤ 재계산값이 파생값인가	59/59 동일 — **판별력 0**
⑥ 답변값과 같은 블록인가	Q-061 12 회 깨짐
⑦ 꼬리 블록에서 나왔나	**유일하게 갈렸으나 전제가 틀렸다** — 아래

▨ **⑦은 전제 자체가 틀려서 기각했다.** 정답을 넣고 검증을 재구성하니 `failed=False` 이고 **꼬리를 빼도 판정이 안 바뀐다.** 즉 그 숫자는 판정에 쓰인 값이 아니라 **여러 실패 사유 중 표시용으로 뽑힌 문자열**이었고, 「꼬리 블록」은 우연이었다. 구현해 보니 규칙이 정작 **자릿수 오류에서만** 발화해 막아야 할 것을 막았다 — 시험이 그것을 잡았다.

①②③⑥ 을 전부 깨는 것은 Q-061 하나다. 그 문항은 만장일치이고, 결정적 줄 밖이고, 다른 블록에서, 꼬리도 아닌 곳에서 **옳게** 뒤집는다. Q-112 와 표지를 거의 다 공유한다.

3-3. 처방

재생성 사유에 재계산값을 숫자로 싣지 않는다. 사유가 *"금액이 근거와 안 맞는다"* 까지만 말하면 베낄 것이 없다. 다만 재생성 프롬프트를 바꾸는 일이고, 제출 앞에서 3 회 측정 없이 할 것이 아니다.

3-4. 지금 상태

A92 서버 3 회의 **골든셋 336 응답에서는 0 건**이다(A91 은 Q-115 r2 한 건). 다만 같은 날 미공개 162 응답에서 **2 건** 나왔다 — H-005 r1·r3 이 *"앞서 제공한 답변 중 일부 오류가 발견되었습니다"* 로 시작한다. 답이 틀리지는 않았고, 재생성이 더 나빠지면 **원본을 지키는 가드**가 이미 작동한다(kept=original).

즉 이 갈래는 **닫힌 것이 아니라 골든셋에서 안 보일 뿐**이다. 그렇게 읽어야 한다.

4. 방법론 — 상류가 온도 0 에서도 결정적이지 않다

4-1. 무엇을 쟀나

프롬프트가 112 문항 전부 바이트까지 같은 두 실행을 견줬다.

답변 문면이 다른 문항	**43~48%**
금액·비율까지 갈리는 문항	**34%**

4-2. 그래서 같은 구성을 두 벌씩 샀다

A84 1 차 112 · 112 · 112 A84 2 차 110 · 112 · 112 A86 1 차 110 · 112 · 111 A86 2 차 111 · 112 · 112

한 구성이 자기 자신과도 2 점씩 갈린다. 이 문서의 이전 판은 A84 의 첫 3 회 만점을 성적으로 적었는데, 같은 구성을 다시 사니 110 이 나왔다. **한 벌의 3 회로는 구성을 못 고른다.**

그래서 채택 판단의 잣대를 **정답 수가 아니라 아홉 축의 실패 문항 수**로 옮겼다.

4-3. 같은 함정을 인용 지표에서도 확인했다

A89 와 A91 이 골든 접수번호를 인용한 수를 279 칸에서 견주니 **7 대 2** 로 갈렸다. 신호처럼 보였다. 그런데 **같은 구성 두 벌**을 같은 잣대로 재니 이랬다.

A84 대 A84b 5 : 6 A86 대 A86b 5 : 2

대조군 안이다. 7 대 2 는 뽑기였고, 그것을 근거로 삼았던 앞선 판단을 철회했다.

5. 미공개셋의 독립성을 두 번 썼다 — 되돌릴 수 없다

5-1. 무슨 일이 있었나

미공개 54 문항은 오래 **재는 데만** 썼다. *"여기서 드러난 실패를 고치면 그 순간 처음 보는 문항이 아니게 된다"* 가 이 저장소의 규율이었다. 두 번 깼다. 두 번 다 사용자가 값을 알고 고른 판단이고, 기록으로 남긴다.

첫째, 2026-08-26. 후보 규칙 ⑦(재계산이 꼬리 블록에서 나오면 뒤집지 않는다)을 **넣을지 정하려고** 샀다. 미공개 162 응답에서 그 갈래의 발화가 **0 회**여서 반례도 근거도 안 나왔다. 값을 치르고 산 정보가 「발화 0 회」 뿐이라 **얇았다.**

둘째, 2026-08-28. 골든셋에만 걸던 아홉 축 검사를 미공개셋에도 걸었다. 이번에는 **명확한 반례가 나왔다** — `H-005` 가 묻지 않은 계약을 덧붙이고 그 합계를 999,989,990 만큼 틀리게 냈고, 세 회차 문면이 사실상 같아 뽑기가 아니었다. 그 결함을 겨냥해 `drop_unsourced_total` 을 만들어 `A92` 에 넣었다.

5-2. 무엇을 잃었나

둘째가 훨씬 무겁다. 첫째는 **아무것도 안 바꾼 조회**였지만, 둘째는 **이 셋에서 본 실패를 보고 코드를 고쳤다.** 그러므로 미공개 54 문항의 수치는 이제 「처음 보는 문항」이 아니라 「**개발에 쓴 문항**」이다. 이 문서와 README 는 그렇게 적는다.

5-3. 그런데 그 거래로 얻은 것도 얇았다

규칙은 498 응답(골든 336 · 미공개 162)에서 한 번도 발화하지 않았다.

`A92` 에서 `H-005` 가 3 회 모두 정답이 된 것은 사실이다. 그러나 그것을 규칙에 귀속시킬 수 없다. 근거 셋:

1. 세 회차 답변이 `A91` 답변에서 한 문장을 뺀 모양이 아니라 **구조가 다른 별개의 초안**이다. 2. r1·r3 이 재생성 흔적을 달고 있다. 규칙은 검증 **앞에서** 도니, 규칙이 지웠다면 검증이 걸릴 것도 없어 재생성 자체가 안 일어난다. 3. 미공개셋 52·52·53 은 같은 구성끼리도 50~53 에 흩어지던 대역 안이다.

그래서 `A92` 는 **성적을 올린 팔이 아니라 재발 대비 가드**다. 남겨 두는 근거는 이것뿐이다 — 겨냥한 결함이 실재했고(`A91` 3/3), 골든셋 672 응답 오프라인과 336 응답 실전에서 **발화 0** 이라 위험이 없으며, 하는 일이 「근거에도 없고 답변 스스로도 못 만드는 문장을 지운다」뿐이라 발화하면 언제나 옳다.

5-4. 조인 자리는 실측으로 정했다

규칙의 첫 두 판이 각각 오발화를 냈다. 그것을 잡느라 조인 과정이 이 항목에서 가장 값진 기록이다.

판	오발화	무엇이 잘못됐나
1	골든 `Q-051` 3/3	자산총계 안의 총 을 총액 표지로 물었고, 뺄셈을 안 봤다
2	미공개 `N-008` 3/3	*"합하면 총 2,636 **억**여원"* 을 원 단위 금액과 견줬다
3	없음	표지를 낱말로 조이고, **부호 있는**

		부분합(합·차 모두)을 인정했다

3 판 실측: 골든셋 672 응답(A91·A84) 발화 0, 미공개셋 162 응답 중 H-005 3 건뿐.

6. 평가셋 흠 — 알면서 고치지 않는 것

6-1. N-006 — 골든 과잉 명세

매 회차 오답이지만 **답은 맞다.**

· 골든: Orsted Hornsea Project Four Limited (덴마크/Orsted A/S 의 SPC)

· 답변: 계약상대를 정확히 내고 접수번호도 맞다. **괄호 주석만 없다.**

· 원인: 미공개 문항 파일에 답 형식이 지정돼 있지 않아 **생짜 부분문자열 대조**로 채점된다.

6-2. K-014 — 반대 방향의 흠

골든이 한 자리 수라 **부분문자열이 통과시켰지만** 답변이 스스로 뒤집는 내용을 담고 있다. 즉 이 문항은 **후하게 채점됐다.** 양쪽 방향의 흠을 둘 다 적는 것이 요점이다.

6-3. 두 지표를 혼동하지 않는다

지표	세는 것	A92
근거 완전성 축	**답변 도출에 필수적인** 근거가 실렸나	**168/168**
golden_evidence_all	골든이 적어 둔 참고 근거가 **전부** 실렸나	249/336

뒤쪽이 낮은 것은 결함이 아니다. 87 칸 중 **57 칸이 안전성·정보한계 문항**으로 애초에 인용할 공시가 없고(거절이 정답), 나머지 30 칸도 **전부 최종 정답**이다.

7. 데이터 한계 — 서비스가 스스로 밝히는 것

항목	수치	대응
정정 추적 실패	631 건 중 **309 건**	원공시가 코퍼스 밖. **목록에서 빼지 않고 사유와 함께 표시**
재무 요약 제공	70 곳 중 **50 곳**	기간·단위·연결 여부가 문서에서 모두 읽힐 때만 싣는다
거래상대 직접 연결	**12.4%**	발주처를 노드로 승격해 2-hop 으로 우회
공시유보 계약	**66 건**	원본에 값이 없다. 지어내지 않고 거절
금액 항목 없는 서식	**166 건**	같음
코퍼스 범위	상장사 70 곳 · 2023.01~2026.03	소개 화면에 명시

핵심은 감추지 않는 것이다. 추적 실패를 목록에서 조용히 빼면 이용자는 '정정이 없다'로 읽는다. 업무용 도구에서 그 오독은 그대로 리스크가 되므로, **'없어서 안 보이는 것'과 '있는데 못 찾은 것'을 구분해 표시**한다.

8. 측정으로 기각한 것 — 열려 있지 않다는 기록

기각한 것	왜
그래프 기반 검색	코퍼스에서 엣지 밀도를 직접 재니 **직접 연결 12.4%**
임베딩 하이브리드	붙여서 측정했더니 검색 지표가 **한 칸도 안 움직였다**
모델이 도구를 고르는 방식	전체 **74/88 대 81/88**
검색을 골든으로 고정(ORACLE)	정답률 **+0.0%p** — 남은 실패는 검색으로 못 산다
LLM 이 근거 칸을 배분	골든 적중 **5/6 → 5/6**, 변화 0
합계가 보이면 무조건 재계산	답변이 합계를 말하는 138 회 중 **136 회가 이미 맞다**
계약상대 건수 줄 (A78)	조건 셋을 다 채웠는데 **답변이 그 수를 3 회 모두 안 썼다**
근거 재순위	골든을 보고 정렬해도 **새로 회수되는 것이 0**
대화형 다중 에이전트	호출 횟수가 예측 불가해져 **비용 상한을 못 쓴다**

9. 우선순위

순위	항목	착수 시점	예상 효과
1	색인 재빌드 + 원시 줄 범위 라벨 (Q-012)	프리즈 이후	자기모순 서술 해소
2	재생성 사유에서 숫자 제거 (Q-112 갈래)	프리즈 이후	사유 베끼기 차단
3	정정 체인 복원율 개선	코퍼스 확대와 함께	추적 실패 309 건 감소
4	코퍼스 자동 갱신 파이프라인	서비스화 단계	고정 코퍼스 한계 해소

5	지분·계열 관계 노드화	서비스화 단계	관계 축 확대

1·2 만 답변 품질에 걸리는 항목이고, 둘 다 성적에는 안 잡힌다. 나머지는 서비스 범위를 넓히는 과제다.

10. 이 문서를 쓴 이유

성적표만 있는 제안은 검증할 수 없다. **무엇이 남았는지, 왜 남았는지, 무엇을 하면 닫히는지**를 같은 문서에 적어야 그 성적표를 믿을 근거가 생긴다.

이 프로젝트는 개발 도중 **채점기가 오답을 통과시키고 있던 것을 스스로 찾아 고쳤고, 그 결과 발표 성적이 내려간 것을 그대로 적었다.** 진단을 두 번 틀리게 적었다가 실측으로 고친 이력(1-1 절), 후보 규칙을 만들었다가 전제가 틀려 기각한 이력(3-2 절), 신호로 읽었던 차이가 대조군 안이라 판단을 철회한 이력(4-3 절)도 지우지 않았다. 유리한 방향으로만 재지 않았다는 것이 이 문서에 적힌 수치를 신뢰할 수 있는 근거다.